

# Cahier des charges du projet Benchtrack

Alexis Lenoir - Xin He - Zhuangzhuang Yang

Vendredi 16 avril 2021

## 1 Contexte et présentation

L'origine de ce projet part du constat qu'il est difficile de comparer des implémentations différentes d'algorithmes avancés. En effet, celles-ci dépendent de nombreux facteurs comme une grande diversité dans les formats d'entrée et de sortie, des conditions d'utilisation et plus simplement du langage de programmation utilisé.

Il existe déjà plusieurs frameworks qui s'occupe de gérer des tests sur des implémentations, comme le module *pytest* et la solution logicielle *Jenkins*. Cependant ils s'attachent à tester pour s'assurer de la validité du code, ils interviennent dans son élaboration, l'objectif du projet se place en aval. En effet, le but du projet n'est pas de développer des implémentations, mais en comparer des préexistantes. Le maître mot est donc comparaison.

L'objectif du projet est donc d'élaborer un framework python, le plus générique possible, de comparaison d'implémentation d'algorithmes complexes qui permettra d'observer et de comparer les performances des différentes implémentations sur différents critères. Le framework générera ainsi un *benchmark*, c'est-à-dire un banc d'essai qui permet d'évaluer la pertinence d'une implémentation à l'aide de comparaisons. Ce benchmark sera ici un site statique qui contiendra tous les résultats des comparaisons. Ce site de comparaison devra pouvoir être mis à jour automatiquement et régulièrement.

## 2 Besoins et contraintes

Le problème est formalisé de la manière suivante. Le but est de générer un *benchmark* pour une *infrastructure de benchmark*. Cette infrastructure est caractérisée par un ensemble d'implémentations d'algorithmes, que l'on appellera *target*. Chaque *target* résoudra au moins une tâche (*task*). Les *tasks* sont eux-même regroupés par thème (*theme*). Le regroupement des *targets* est assez structuré mais il sera toujours possible d'indiquer un nom par défaut. De ce formalisme découle naturellement une arborescence *infrastructure\_de\_test/theme/task*.

Une problématique majeure est le formalisme adopté : il doit être clair et efficace, tout en restant le plus générique possible.

L'intérêt de ce benchmark dépend fortement des critères pris en compte. Le plus trivial est la vitesse d'exécution. Cependant, il n'est pas chose aisée de la calculer.

Comme il a été dit précédemment, le *benchmark* sera impérativement un site statique, ce framework produira donc un site statique (html/css/javascript). Afin d'optimiser le développement, sera adoptée une approche modulaire : le projet sera séparé en deux. La première partie consistera à générer les résultats dans un fichier *output\_date.csv*. La deuxième partie produira le site benchmark à l'aide de *output\_date.csv*.

Le projet sera développé en python.

## 2.1 Description générale d'une *infrastructure de benchmarks* :

### La structure principale

Ce logiciel prend en entrée le chemin absolu d'une *infrastructure de benchmark*, ce sera un répertoire. Les *themes* et les *tasks* seront représentés par des sous-répertoires. Les *targets* proposent un code résolvant une ou plusieurs *tasks*. Dans le répertoire de l'infrastructure, il y aura deux sous-répertoires : *targets* (voir les fichiers annexes) et *tasks* qui contiendra les répertoires *themes*, qui eux-même contiendront une répertoire pour chaque *task* de ce theme. Chaque *target* qui décrit une *task* sera présent dans ce sous-répertoire.

### Les fichiers annexes

Après avoir abordé les données brutes, il y a aussi les fichiers indispensables de configuration et de documentation. Dans le répertoire de l'*infrastructure de test* se trouvera un fichier *README.rst* qui présentera l'infrastructure. On trouvera aussi un répertoire *targets*. Pour chaque *target* sera associée un sous-répertoire */nom\_infrastructure\_benchmark/targets/nom\_target*. Il contiendra un fichier de configuration *config.ini* qui précisera le langage, comment l'exécuter et la mettre à jour. Comme par exemple :

```
[execution]
language = python
run =python {script} {arg}
upgrading=pip install --upgrade pyAgrum
```

Et un fichier *README.rst* qui décrira la target.

Pour chaque *task*, on trouvera dans le répertoire associée un sous-répertoire *data* qui contiendra éventuellement les données d'entrée de la tâche, tous les formats seront acceptées. Un fichier *README.rst* décrivant la *task* sera aussi

présent dans le répertoire, tout comme un fichier de configuration *config.ini*, pour indiquer la liste des arguments, comme par exemple :

```
[running]
sample_size=5
args=asia.bif,alarm.bif,Mildew.bif,Diabetes.bif
```

Format général :

```
/nom_infrastructure_benchmark
  /README.rst
  /targets
    /target1
      /README.rst
      /config.ini
    /target2
      /README.rst
      /config.ini
  /tasks
    /theme1
      /task1
        /README.rst
        /config.ini
        /data
        /target1.py
        /target2.r
      /task2
        /README.rst
        /config.ini
        /data
        data_task2.csv
        /target2.r
    /theme2
      /task3
        /README.rst
        /config.ini
        /data
        /target1.py
        /target2.r
```

## 2.2 Exemple d'une *infrastructure* : PGM

Pour les modèles probabilistes graphiques (PGM), on voudrait comparer quelques bibliothèques (pyAgrum, pyPGM, BNLearn) sur un ensemble de tâches parfois spécifiques traitant de l'apprentissage, de l'ingérence probabiliste et de la modélisation.

On a ainsi l'arborescence suivante :

```

/PGM
  /README.rst
  /targets
    /pyAgrum
      /config.ini
      /README.rst
    /pyPGM
      /config.ini
      /README.rst
  /BNLearn
    /config.ini
    /README.rst

/tasks
  /learning
    /parameterLearning
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
      /BNLearn.r
    /parameterLearningWithMissingValues
      /README.rst
      /data
      /pyAgrum.py
      /BNLearn.r
    /structuralLearning
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
      /BNLearn.r
  /inference
    /exactInference
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
    /multipleExactInference
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
    /approximatedInferenceGibbsSampling
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
      /BNLearn.r
  /modelisation
    /modelingAsia
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
      /BNLearn.r
    /modelingAlarm
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
      /BNLearn.r
    /modelingPRM
      /README.rst
      /data
      /pyAgrum.py
      /pyPGM.py
      /BNLearn.r

```

## 2.3 Autre exemple d'une infrastructure : ConfigFichier

On voudrait comparer différents formats de fichier de configuration (ini/json/xml) et leurs implémentations en python. Il s'agit donc de comparer la lecture de quelques exemples de fichier de configuration (ici deux) dans les différents formats. Il n'y a pas besoin d'une structuration en theme des deux seuls tasks.

/ConfigFichier

/README.rst	/tasks
/targets	/default
/ini_demo	/charger_employe
/README.rst	/README.rst
/config.ini	/config.ini
/json_demo	/data
/README.rst	/employe.ini
/config.ini	/employe.json
/xml_demo	/employe.xml
/README.rst	/ini_demo.py
/config.ini	/json_demo.py
	/xml_demo.py
	/charger_employe_coordonnees
	/README.rst
	/config.ini
	/data
	/employe_coordonnees.ini
	/employe_coordonnees.json
	/employe_coordonnees.xml
	/ini_demo.py
	/json_demo.py
	/xml_demo.py

## 2.4 Description de l'affichage des résultats : un site statique

Le logiciel sauvegardera dans un premier temps les résultats dans un fichier csv. Le format de ce fichier sera :

```
theme,task,target, args, run_time
...
```

La première ligne indique le nom des colonnes. Ensuite pour les résultats de chaque target il y a une ligne : le thème et la tâche associée y sont renseignés, on précise aussi les éventuels arguments. Dans la première version, il y aura qu'un seul résultat : la vitesse d'exécution (run\_time). Si le temps n'a pas pu être calculer une valeur d'erreur sera écrite (-2).

Une étape importante consistera à générer un fichier rst à partir du fichier csv. La librairie *pelican* sera alors utilisée pour produire des fichiers html.

Le site sera constitué des pages suivantes :

- Une page de résumé : un texte de présentation de l'infrastructure, une matrice task x target pour les résultats.
- Une page par task : une présentation de la tâche, le résultat par target.
- Une page par target : une présentation de la target, le résultat par task.
- Une page par target d'une task : le résultat, l'affichage du code associé

Il est possible de possible de personnaliser le site en choisissant un favicon et un logo qu'il faudra placer dans un répertoire img dans le répertoire de l'infrastructure.

Une répertoire nameInfra\_site qui contiendra le site statique sera généré et stocké par défaut dans le répertoire du framework Benchtrack, mais on pourra cependant préciser où on veut l'exporter.

### 3 Objectifs d'une première version

#### 3.1 Fonctionnalités générales :

Un script python qui en prenant en paramètre une infrastructure (un repertoire) génère un site html(benchmark).

Les critères utilisées dans l'étude sont :

- La vitesse d'exécution

#### 3.2 Fonctionnement du framework :

Notre logiciel sera appelé à l'aide du fichier *benchTrack.py*. On utilisera le logiciel de la manière suivante :

```
python benchTrack.py path_infrastructure_benchmark
```

où *infrastructure\_de\_benchmark* sera un répertoire respectant le formalisme qui a été défini précédemment.

Plus précisément, *benchTrack.py* produira dans un premier temps *output\_date.csv* qui contiendra les résultats des exécutions.

Il appellera ensuite *bench2site.py* avec *output\_date.csv* pour produire le répertoire nameInfra\_site qui contiendra le site statique et nameInfra\_pelican qui contiendra le site plus les fichiers de paramètres pelican.

#### 3.3 Le critère de vitesse d'exécution :

Dans un premiers temps, on calculera simplement la vitesse d'exécution. Cette opération sera répétée plusieurs fois pour augmenter la précision. On pourra aussi calculer le temps de chargement des données, qui pourra être soustrait pour affiner l'estimation.

## 4 Autres fonctionnalités

- Le Framework s’installe comme un package pip
- Prend en compte plusieurs langages : Python, R
- Commandes personnalisées et descriptives dans le terminale :

```
python benchtrack.py --output HTML_FOLDER
python benchtrack.py --verbose
python benchtrack.py --targets-list
python benchtrack.py --tasks-list
python benchtrack.py --target-info TOTO
python benchtrack.py --task-info A
python benchtrack.py --targets-include=TOTO,TITI
python benchtrack.py --tasks-include=A,B,C
python benchtrack.py --targets-exclude=TOTO,TITI
python benchtrack.py --tasks-exclude=A,B,C
```

## 5 Améliorations futures

Le framework pourra posséder les améliorations suivantes :

- Prendre en compte plus de langages
- Augmenter le nombre de critère dans l’évaluation de la comparaison
- Améliorer l’affichage du site statique
- Conserver en mémoire les résultats, pour les comparer entre eux, montrer ainsi l’évolution
- Personnaliser d’avantage l’interaction avec le framework en augmentant les commandes possibles avec le terminale.
- Faciliter la création d’une infrastructure de test, en générant automatiquement l’arborescence à partir d’un fichier de configuration.
- Pouvoir vérifier la précision des résultats obtenus, en connaissant les résultats attendus qui seraient sauvegardés dans un répertoire *expected*

## 6 Délai

Une première version fonctionnelle doit être achever avant le lundi 1er mars 2021.

La dernière version de notre projet doit être réaliser avant le lundi 17 mai 2021.